

스파르타 **Kant** 시연 강의

AI 리터러시 & 프롬프트 엔지니어링 / RAG

PART 1

AI 리터러시 & 프롬프트 엔지니어링

1. AI 리터러시 & 프롬프트 엔지니어링
2. 프롬프팅 패턴
3. 시스템 프롬프트
4. 구조화 출력

1. AI 리터러시 & 프롬프트 엔지니어링

AI 리터러시

- AI를 **이해**하고, **한계**를 알고 **비판적**으로 판단하며, 목적에 맞게 **활용**하는 능력

프롬프트 엔지니어링

- 원하는 결과를 얻기 위해 AI에게 주는 입력을 **설계**하고, **테스트**하고, **개선**하는 일

AI를 **이해**하는 것에서 시작해, AI에게 **올바르게 지시**하는 방법

LLM

Large



방대한 데이터와
거대한 규모

Language



사람의 언어를
다룸

Model



다음 단어를
예측하는 모델

방대한 글을 학습해, 사람의 언어를 이해하고 만들어 내는 AI

LLM은 어떻게 **답**을 만들까?

질문

비 오는 날 점심 메뉴 추천해 줘

AI

비 오는 날엔 따뜻한 국물 요리 어때요?

다음 단어를 하나씩 **예측**해서 문장을 만든다

외운 게 아니라 **패턴**을 익혔다 → 처음 보는 질문에도 답한다

프롬프트가 중요한 이유

프롬프트

점심 메뉴 추천해 줘

- + 비 오는 날
- + 국물 있는 걸로
- + 한식 면 요리로

AI가 고를 수 있는 답

1 개

짜장면

샐러드

국밥

파스타

초밥

칼국수

김밥

냉면

햄버거

떡볶이

순두부

우동

구체적일수록 → 답의 범위는 좁아지고, 결과는 의도에 가까워진다

프롬프트 엔지니어링 = 이 원리로 원하는 결과를 얻도록 지시를 설계하는 일

AI의 한계

환각

Hallucination

사실이 아니라 **확률**로
고른다 → 그럴듯한 **거짓**

예

"세종대왕 맥북 던짐 사건"을
실제 역사처럼 설명

지식 컷오프

Knowledge Cutoff

학습이 끝난 **이후**는
모른다

예

"어제 경기 결과 알려 줘"
※ 웹 검색으로 상당 부분 보완

편향

Bias

데이터가 **치우치면**
답도 치우친다

예

"아침 식사 추천해 줘"
→ 팬케이크·베이컨 등 서양식 위주

한계를 알아야 → AI의 답을 **비판적**으로 판단할 수 있다

정리

1 LLM은 앞의 **문맥**을 보고 다음 단어를 고른다

↓ 처음에 AI가 보는 문맥은 **프롬프트**

2 **프롬프트**가 바뀌면 답이 바뀐다

→ 구체적일수록 의도에 가까워진다

↓ 하지만

3 **환각 · 지식 컷오프 · 편향**이 있다

↓ 그래서

4 **이해**하고, **비판적**으로 판단하고, **잘 지시**해야 한다

= AI 리터러시 & 프롬프트 엔지니어링

2. 프롬프팅 패턴 - 어떻게 **지시**할까?

제로샷

Zero-shot

퓨샷


Few-shot

CoT

Chain of Thought

Shot이란?

shot = 예시 하나



제로샷 0개



원샷 1개



퓨샷 몇 개

용어의 배경

- 과거** 고양이 하나를 알아보려면 사진 수만 장을 학습
→ 이미 아는 걸 활용해 1장, 0장으로 배울 수 없을까? ('말'을 아는 AI에게 "줄무늬 있는 말" → 얼룩말)
- 2020** GPT-3: 방대한 글로 이미 수많은 패턴을 익힘
→ 다시 학습하지 않고, 예시 몇 개만 보고 새로운 일을 해냄

예시가 왜 중요할까?

제로샷

다음 리뷰를 배송 불만, 품질 불만, 칭찬 중 하나로 분류해 줘.

포장도 꼼꼼하고 디자인도 사진이랑 똑같이 예뻐요. 선물용으로 딱이에요. 다만 뚜껑이 조금 뻑뻑해요.

AI ▶ 칭찬

퓨샷

팀 기준: 불만이 하나라도 있으면 → 불만

다음 예시를 참고해 리뷰를 분류해 줘.

일주일이지났는데 아직 안 왔어요

→ 배송 불만

한 번 세탁했더니 색이 다 빠졌어요

→ 품질 불만

디자인은 마음에 드는데 배송이 열흘 걸렸어요

→ 배송 불만

가격 대비 다 좋은데 단추 하나가 덜렁거려요

→ 품질 불만

포장도 꼼꼼하고 제품도 마음에 들어요

→ 칭찬

포장도 꼼꼼하고 디자인도 사진이랑 똑같이 예뻐요. 선물용으로 딱이에요. 다만 뚜껑이 조금 뻑뻑해요. →

AI ▶ 품질 불만

팀만 아는 기준은, 예시로 보여 줘야 한다

CoT - Chain of Thought

암산

$$5x - 28 = 2x + 2$$

$$x = ? \text{ 🌀}$$

단계적으로 생각하면

$$\textcircled{1} \quad 5x - 2x = 2 + 28$$

$$\textcircled{2} \quad 3x = 30$$

$$\textcircled{3} \quad x = 10 \quad \checkmark$$

바로 답하지 말고, 단계를 나눠 생각하게 한다

용어의 배경

2022 예시에 풀이 과정까지 넣었더니 → 추론 문제 정확도가 크게 향상
"단계별로 생각해 보자" 한 줄만 넣어도 → 비슷한 효과

CoT 적용해 보기

일반 질문

로그인 후 가끔 장바구니가 비어 보여.
원인이 뭐야?

AI
캐시 문제일 가능성이 높아요.
브라우저 캐시를 지워 보세요.

CoT 적용

로그인 후 가끔 장바구니가 비어 보여.

- ① 가능한 원인을 먼저 나열하고
- ② 각각이 '가끔'이라는 증상과 맞는지 하나씩 따져 본 다음
- ③ 가장 가능성 높은 원인을 골라 줘

AI

- ① 원인 후보: 캐시 · 세션 만료 · 로그인과 장바구니 불러오기 순서
- ② '가끔'과 맞는지

캐시	매번 생길 문제	×
세션 만료	시간이 지나야 생김	△
순서 어긋남	타이밍에 따라 가끔	○
- ③ 결론: 로그인 처리와 장바구니 불러오기 순서가 어긋남

생각하는 순서를 정해 주면, 원인을 좁혀 간다

※ 최근 추론 모델은 스스로 생각하지만, 판단 순서를 직접 정하고 싶을 때는 여전히 유효

정리 - 필요한 만큼 더한다

작업이 복잡해질수록 →

제로샷

지시만

상식으로 판단할 수 있는 일

퓨샷

+ 예시

팀만의 기준이 있거나
출력 형식을 맞춰야 하는 일

CoT

+ 생각하는 순서

여러 단계의 판단이
필요한 일

최신 모델도 **우리 팀의 기준과 형식**은 모른다 → 퓨샷 · CoT로 전달

매번 전달하는 규칙을 고정해 두려면? ▶ 시스템 프롬프트

3. 시스템 프롬프트

AI = 지식은 많지만, **우리 팀 규칙**은 모르는 신입 직원

시스템 프롬프트 = 업무 매뉴얼

고정

당신은 기술 문서를 요약하는 어시스턴트입니다.
항상 **핵심 개념**, **활용 예시**, **주의사항**으로 나누어 설명하세요.

↓ 모든 대화에 적용

유저 프롬프트 RAG가 무엇인지 설명해 줘

매번 바뀜

유저 프롬프트 LLMOps는 뭐야?

매번 바뀜

한 번 설정 → 이후 **모든 대화**에 계속 적용

무엇을 **답을**까?

1 역할

관점과 말투가 달라진다

2 맥락과 이유

이유를 알면 비슷한 상황에도 같은 판단

3 출력 형식

"하지 마"보다 "이렇게 해"

4 예시

완성본을 직접 보여 준다

5 행동 방식

모호하면 질문, 되돌리기 어려우면 확인

<role>

당신은 이커머스 고객 리뷰를 분류하는 CS 담당자입니다.

</role>

<context>

분류 결과는 고객 대응 우선순위를 정하는 데 사용됩니다.

따라서 칭찬이 섞여 있어도 불만이 하나라도 있으면 불만으로 분류하세요.

</context>

<format>

배송 불만, 품질 불만, 칭찬 중 하나의 라벨만 출력하세요.

리뷰만으로 판단하기 어려우면 "확인 필요"를 출력하세요.

</format>

<examples>

디자인은 마음에 드는데 배송이 열흘 걸렸어요 → 배송 불만

포장도 꼼꼼하고 제품도 마음에 들어요 → 칭찬

</examples>

프롬프트가 길어지면, **<태그>** 나 **# 제목** (마크다운) 으로 **구역을** 나눈다

어디에 넣을까?

채팅 도구

Claude · ChatGPT

프로젝트 지침

코딩 도구

**Claude Code ·
Cursor**

CLAUDE.md · rules 파일


서비스 개발

API 호출

system 값

위치는 달라도, 역할은 같다

예: Claude 프로젝트 지침



여기에
시스템 프롬프트를 입력

이 프로젝트의
모든 대화에 적용된다

서비스 개발에서는

```
client.messages.create(  
    model="...",  
    max_tokens=1024,  
    system="당신은 이커머스 고객 리뷰를 분류하는 CS 담당자입니다. ...",  
    messages=[{"role": "user", "content": "리뷰: 배송은 빨랐는데 사이즈가 생각보다 작아요."}]  
)
```

개발자가 미리 정해 둬

사용자는 질문만 입력

시스템 프롬프트는 **사용자에게 보이지 않는다**

형식을 정해도, **항상** 지키진 않는다

시스템 프롬프트: "하나의 라벨만 출력하세요"

AI 답변	프로그램
품질 불만	✓ 처리
품질 불만입니다.	✗ 처리 실패
품질 불만	✗ 처리 실패
분류: 품질 불만	✗ 처리 실패

사람은 알아보지만, **프로그램**은 한 글자만 달라도 문제

형식을 확실하게 지키게 하려면? ▶ 구조화 출력

4. 구조화 출력

AI 답변을 서비스 화면에 바로 보여준다면?

```
{
  "topic": "RAG",
  "summary": "외부 문서를 검색해  
LLM 답변 품질을 높이는 구조",
  "use_case": ["사내 문서 검색", "정책 Q&A"],
  "risk": "검색 품질이 낮으면 잘못된 답변 가능"
}
```

JSON = 키 : 값 쌍으로 된 데이터 형식

→
키로 찾아서 표시

서비스 화면

RAG

외부 문서를 검색해 LLM 답변 품질을 높이는 구조

사내 문서 검색

정책 Q&A

▲ 검색 품질이 낮으면 잘못된 답변 가능

구조화 출력 = AI 답변을 미리 정한 구조(JSON)로 받는 방식

구조가 흔들리면

의도한 구조

```
{
  "topic": "RAG",
  "summary": "외부 문서를...",
  "use_case": [
    "사내 문서 검색",
    "정책 Q&A"
  ],
  "risk": "검색 품질이..."
}
```

키 이름이 바뀌면

```
{
  "주제": "RAG",
  "요약": "외부 문서를...",
  "사용케이스": [
    "사내 문서 검색",
    "정책 Q&A"
  ],
  "위험": "검색 품질이..."
}
```

데이터 형태가 바뀌면

```
{
  "topic": "RAG",
  "summary": "외부 문서를...",
  "use_case_1": "사내 문서 검색",
  "use_case_2": "정책 Q&A",

  "risk": "검색 품질이..."
}
```

`data["topic"]`

→ 값을 찾지 못함 →

화면이 비거나 오류

구조를 고정하는 방법

프롬프트에 구조 명시 퓨샷과 같은 원리

RAG를 정리해 줘.
아래 구조의 JSON만 출력해.

```
{ "topic": "주제", "summary": "한 문장 요약",  
  "use_case": ["활용 사례"], "risk": "주의할 점" }
```

결과

✓ 매번 같은 키를 가진 JSON

topic · summary · use_case · risk

구조를 명시하면, AI가 그 구조에 맞춰 답한다

시연 - 구조를 지정하면

구조 미지정

RAG를 주제, 요약, 활용 사례, 위험 요소로 정리해 줘

RAG (Retrieval-Augmented Generation, 검색 증강 생성)

1. 주제

대규모 언어모델(LLM)이 답하기 전에 외부 지식을 검색해 근거로 활용하는 기법입니다. 모델이 학습한 지식만으로 답하는 대신, 질문과 관련된 문서를 먼저 찾아 프롬프트에 함께 넣어 줍니다. 2020년 Meta(당시 Facebook AI)의 Lewis 등이 발표한 논문에서 이름이 붙었습니다.

2. 요약

작동 흐름

1. 색인(Indexing): 문서를 적당한 크기의 조각(chunk)으로 나누고 임베딩 벡터로 변환해 벡터 DB에 저장
2. 검색(Retrieval): 사용자 질문도 임베딩해서 의미가 가까운 조각을 찾음 (키워드 검색과 섞는 하이브리드 방식도 혼용)
3. 재정렬(Reranking, 선택): 찾은 후보 중 정말 관련 있는 것만 골라 순서를 다시 매김
4. 생성(Generation): 질문과 검색된 조각을 함께 LLM에 넣어 근거 기반 답변 생성

→ 제목·문장·목록이 섞인 자유 형식

구조 지정

RAG를 아래 JSON 구조에 맞춰 정리해 줘.
JSON 외의 다른 텍스트는 출력하지 마.
{ "topic": "주제", "summary": "한 문장 요약",
"use_case": ["활용 사례"], "risk": "주의할 점" }

```
{  
  "topic": "RAG (Retrieval-Augmented Generation, 검색 증강 생성)",  
  "summary": "RAG는 대규모 언어 모델이 답변을 생성하기 전에 외부 문서나 데이터베이스에서 관련 정보를 검색해  
참고하도록 하여, 최신성과 정확성을 높이는 기법이다.",  
  "use_case": [  
    "사내 문서·매뉴얼 기반 질의응답 챗봇",  
    "고객 지원 FAQ 자동 응답",  
    "법률·의료·금융 등 전문 문서 검색 및 요약",  
    "최신 뉴스나 제품 정보를 반영한 답변 생성",  
    "논문·연구 자료 탐색 및 근거 제시"  
  ],  
  "risk": "검색된 문서의 품질과 관련성에 답변 정확도가 크게 좌우되므로, 부정확하거나 오래된 자료, 잘못된 청크 분할,  
검색 실패 시 환각이 여전히 발생할 수 있고, 민감 정보가 포함된 문서의 접근 권한 관리와 출처 검증이 필요하다."  
}
```

→ 정한 키 그대로 JSON

프롬프트만으로도 대부분 지키지만, 보장은 아니다

코드로 한 번 더 검증



거의 항상 맞지만, 가끔 예외가 생긴다

1. 검증

정한 구조가 맞는지 확인

2. 재시도

틀리면 다시 요청

3. 폴백

그래도 안 되면 대체 응답

구조는 프롬프트로 정하고, 코드로 한 번 더 검증한다

PART 2

RAG

1. RAG가 필요한 이유
2. 기본 RAG 파이프라인
3. 검색 품질을 높이는 핵심 요소

1. RAG가 필요한 이유

질문

우리 학교에서 휴학은 최대 몇 학기까지 가능해?

AI

우리 학교 규정이 아닌, **일반적인 대학 기준**으로 답한다

LLM이 학습한 적 없는 정보

최신 정보 = 지식 컷오프

학습이 끝난 **이후**에 생긴 일

공개되지 않은 정보

학교 학사 규정 · 회사 내부 문서

학습한 적 없는 내용도, **그렇듯하게** 답을 만들어 낸다

모르는 정보를 알려 주려면? ▶ RAG

RAG

Retrieval



검색

질문과 관련된
문서 조각을 찾는다

Augmented



보강

찾은 내용을 질문과 함께
프롬프트에 넣는다

Generation



생성

찾은 내용을 **근거**로
답을 만든다

모델은 **그대로** 두고, **찾은 문서**를 근거로 답하게 한다

다른 방법은 없을까?

파인튜닝

모델을 다시 학습

- ✗ 바뀔 때마다 재학습, 비용 큼
- ✗ 근거 확인이 어렵다

비유

시험 범위를 통째로 외우기

문서 전체 넣기

모든 문서를 프롬프트에

- ✗ 한 번에 읽을 수 있는 양을 넘는다
- ✗ 비용이 크게 늘어난다

비유

매번 책 한 권을 다 읽기

RAG

질문마다 필요한 부분만 찾아서

- ✓ 질문마다 자동으로 골라 넣음
- ✓ 답의 출처를 함께 보여 줌
- ✓ 바뀐 문서만 다시 넣으면 갱신

비유


필요한 페이지만 펴 보는 오픈북 시험

문서가 많고 자주 바뀐다면 → RAG가 가장 현실적

2. 기본 RAG 파이프라인


준비 단계

인덱싱
문서가 바뀔 때만



질문 단계

질문할 때마다



책에 색인을 붙여 두고, 문제가 나오면 찾아 펴 본다

준비 단계 - 인덱싱

준비

수집

청킹

임베딩

저장

질문

임베딩

검색

보강


생성



임베딩 - 의미를 숫자로

"학교를 잠시 쉬고 싶다" → $[0.10, -0.45, 0.33, \dots]$ 숫자 수백~수천 개 (모델마다 다름)

의미 지도



단어가 달라도, 의미가 가까우면 찾는다

임베딩 모델

모델	숫자 개수	실행 방식	한 번에 넣는 길이	특징
예시 sentence-transformers paraphrase-multilingual-MiniLM-L12-v2	384	무료 공개 내 컴퓨터에서 실행	128토큰 짧은 글용	50여 개 언어 (한국어 포함), 가벼움
OpenAI text-embedding-3-small	1536 줄여 쓰기 가능	API 쓴 만큼 요금	8,192토큰	더 큰 모델(-large)은 3072개
BAAI bge-m3	1024	무료 공개 내 컴퓨터에서 실행	8,192토큰	100개 이상 언어
Voyage AI voyage-4	1024 256~2048 선택	API 쓴 만큼 요금	32,000토큰	Claude 공식 문서가 소개 Anthropic은 자체 임베딩 모델 없음

고르는 기준: 다루는 언어 · 넣을 글의 길이 · 비용 · 실행 방식

문서와 질문은 반드시 같은 모델로 바꾼다

질문 단계 - 검색

준비 수집 청킹 임베딩 저장 질문 **임베딩** **검색** 보강 생성

질문

Kant 대학교에서 학교를 잠시 쉬고 싶은데, 최대 몇 학기까지 쉴 수 있어?

→ 같은 모델로 숫자 목록 [0.12, -0.41, 0.29, ...]

유사도 순위

1	제12조 (휴학)		0.82
2	제13조 (복학)		0.61
3	제5조 (수강신청)		0.24

↑ 상위 2개만 골라 프롬프트에 넣는다

'휴학'이라는 단어 없이 물어도, 휴학 조항이 1위

보강 - LLM에 가는 프롬프트

준비 수집 청킹 임베딩 저장 질문 임베딩 검색 **보강** 생성

시스템 프롬프트 사용자에게 안 보임

당신은 Kant 대학교 학사 안내 도우미입니다.

<규정> 안의 내용만 근거로 답하고, 근거 조항을 함께 알려 주세요.

개발자가 미리 작성

사용자 메시지

<규정>

제12조 (휴학) 학생은 질병, 군 입대, 개인 사정 등의 사유로 휴학할 수 있다. 일반 휴학은 한 번에 최대 2학기까지 신청할 수 있으며, 재학 기간 중 통산 6학기를 넘을 수 없다. 군 입대로 인한 휴학 기간은 통산 휴학 기간에 포함하지 않는다.

제13조 (복학) 휴학 기간이 끝난 학생은 해당 학기 시작 30일 전까지 복학 신청을 해야 한다. 기간 안에 복학 신청을 하지 않으면 제적될 수 있다.

</규정>

검색 결과가 자동으로

질문: Kant 대학교에서 학교를 잠시 쉬고 싶은데, 최대 몇 학기까지 쉴 수 있어?

사용자가 입력

RAG도 결국, 찾은 내용을 프롬프트에 넣어 주는 것

생성 - 답이 달라진다

준비 수집 청킹 임베딩 저장 질문 임베딩 검색 보강 **생성**

검색 없이

AI

Kant 대학교의 규정은 확인되지 않지만, **일반적으로 대학은** 휴학을 통산 4~6학기 정도 허용합니다.
정확한 내용은 학교에 확인하세요.

RAG 적용

AI

일반 휴학은 한 번에 **최대 2학기**, 재학 중 **통산 6학기**까지 쉴 수 있습니다. 군 입대로 인한 휴학은 통산 기간에 포함되지 않습니다.

근거: 제12조 (휴학)

모델은 **그대로**, 규정을 프롬프트에 넣었을 뿐인데 **답이 달라졌다**

3. 검색 품질을 높이는 핵심 요소

엉뚱한 조각 검색



LLM



그럴듯한 오답

오픈북 시험에서 엉뚱한 페이지를 편 센

1

넣기

문서와 청킹

준비 단계

2

찾기

검색 방식

질문 단계 · 검색

3

고르기

결과 선별

검색 후 · 보강 전

넣기 - 문서와 청킹

준비 수집 **청킹** 임베딩 저장 질문 임베딩 검색 보강 생성

너무 작게

문장 하나씩

"**기간** 안에 복학 신청을 하지 않으면
제적될 수 있다."

✗ 무슨 기간? 맥락이 끊긴다

비유 책을 한 줄씩 잘라 둔 셈

너무 크게

규정 전체를 한 덩어리로

제1조 (목적) ... 제5조 (수강신청) ...
제12조 (휴학) ... 제20조 (학사 경고) ...

✗ 관계없는 내용이 섞인다

✗ 핵심이 흐려진다

비유 챕터를 통째로 준 셈

구조대로

조항 · 제목 · 문단 단위로

제13조 (복학) 휴학 기간이 끝난 학생은 ...
30일 전까지 복학 신청을 해야 한다. ...

✓ 의미 단위가 온전히 남는다

비유 목차대로 나눈 셈

더 행길 것 **오버랩** 앞뒤 조각을 조금 겹쳐, 경계에서 끊기지 않게 **문서 품질** 폐지된 규정 · 옛 버전은 빼 둔다

검색은 **저장된 조각 안에서만** 일어난다 → 조각을 잘 만드는 것이 출발점

찾기 - 검색 방식


질문이 "제13조 내용 알려줘"였다면?

	의미 검색 임베딩 · 뜻이 가까운 것	키워드 검색 단어 일치 · 같은 단어가 있는 것	하이브리드 검색 두 방식을 함께
"학교를 잠시 쉬고 싶은데 얼마나 쉴 수 있어?"	✓ 제12조	✗ '휴학' 단어 없음	✓ 제12조
"제13조 내용 알려줘"	△ 놓칠 수 있음	✓ 제13조	✓ 제13조

표현이 다른 질문도, 정확한 단어도 → 두 방식을 함께 쓴다

고르기 - 결과 선별

준비 수집 청킹 임베딩 저장 질문 임베딩 **검색** **보강** 생성



답이 이상하면, 프롬프트보다 먼저 어떤 조각이 검색됐는지 확인한다

정리 - 좋은 답은 좋은 문맥에서

1 LLM은 앞의 문맥을 보고 답을 만든다

↓ 그래서

2 지시를 잘 쓴다

패턴 · 시스템 프롬프트 · 구조화 출력

↓ 하지만 모르는 정보는 지시만으로 안 된다

3 근거를 찾아 넣는다

RAG = 검색 · 보강 · 생성

↓ 그리고

4 결과를 확인한다

형식은 코드로 검증 · 이상한 답은 검색된 조각부터

PART 1

PART 2

PART 1 · 2

잘 지시하고, 근거를 넣고, 확인한다